

Analizador Léxico C-Minus - Compiladores 2026.2

Guilherme Rozenblat e Leonardo Valladares

Repositório: <https://github.com/GuilhermeRozenblat/compiler-c-minus>

1. Linguagem escolhida:

Escolhemos C-Minus, com base no livro Compiler Construction: Principles and Practice, de Kenneth C. Louden. A gramática tem 29 regras:

1. $\text{program} \rightarrow \text{declaration-list}$
2. $\text{declaration-list} \rightarrow \text{declaration-list declaration} \mid \text{declaration}$
3. $\text{declaration} \rightarrow \text{var-declaration} \mid \text{fun-declaration}$
4. $\text{var-declaration} \rightarrow \text{type-specifier ID} ; \mid \text{type-specifier ID} [\text{NUM}] ;$
5. $\text{type-specifier} \rightarrow \text{int} \mid \text{void}$
6. $\text{fun-declaration} \rightarrow \text{type-specifier ID} (\text{params}) \text{compound-stmt}$
7. $\text{params} \rightarrow \text{param-list} \mid \text{void}$
8. $\text{param-list} \rightarrow \text{param-list} , \text{param} \mid \text{param}$
9. $\text{param} \rightarrow \text{type-specifier ID} \mid \text{type-specifier ID} []$
10. $\text{compound-stmt} \rightarrow \{ \text{local-declarations statement-list} \}$
11. $\text{local-declarations} \rightarrow \text{local-declarations var-declaration} \mid \text{empty}$
12. $\text{statement-list} \rightarrow \text{statement-list statement} \mid \text{empty}$
13. $\text{statement} \rightarrow \text{expression-stmt} \mid \text{compound-stmt} \mid \text{selection-stmt} \mid \text{iteration-stmt} \mid \text{return-stmt}$
14. $\text{expression-stmt} \rightarrow \text{expression} ; \mid ;$
15. $\text{selection-stmt} \rightarrow \text{if} (\text{expression}) \text{statement} \mid \text{if} (\text{expression}) \text{statement} \text{else statement}$
16. $\text{iteration-stmt} \rightarrow \text{while} (\text{expression}) \text{statement}$
17. $\text{return-stmt} \rightarrow \text{return} ; \mid \text{return expression} ;$
18. $\text{expression} \rightarrow \text{var} = \text{expression} \mid \text{simple-expression}$
19. $\text{var} \rightarrow \text{ID} \mid \text{ID} [\text{expression}]$
20. $\text{simple-expression} \rightarrow \text{additive-expression} \text{relop additive-expression} \mid \text{additive-expression}$
21. $\text{relop} \rightarrow < = \mid < \mid > \mid > = \mid = = \mid ! =$
22. $\text{additive-expression} \rightarrow \text{additive-expression} \text{addop term} \mid \text{term}$
23. $\text{addop} \rightarrow + \mid -$
24. $\text{term} \rightarrow \text{term} \text{mulop factor} \mid \text{factor}$
25. $\text{mulop} \rightarrow * \mid /$
26. $\text{factor} \rightarrow (\text{expression}) \mid \text{var} \mid \text{call} \mid \text{NUM}$
27. $\text{call} \rightarrow \text{ID} (\text{args})$
28. $\text{args} \rightarrow \text{arg-list} \mid \text{empty}$
29. $\text{arg-list} \rightarrow \text{arg-list} , \text{expression} \mid \text{expression}$

As palavras reservadas são else, if, int, return, void e while. Os símbolos são + - * / < <= > >= == != = ; , () [] { } . Um identificador segue a regra $\text{ID} = \text{letter letter}^*$, com $\text{letter} = [\text{a-zA-Z}]$.

Um número segue $NUM = digit\ digit^*$, com $digit = [0-9]$.

A linguagem aceita comentários entre $/^*$ e $*/$, sem aninhamento. Espaços e quebras de linha separam os tokens.

2. Scanner manual:

2.1. Subconjunto e expressões regulares:

Selecionamos as regras 4, 5, 16, 17, 18 e 21 da BNF: declaração de variável, tipo, while, return, expressão e operadores relacionais. Elas formam um subconjunto de 18 tokens.

ID: letter letter*

NUM: digit digit*

INT: int

VOID: void

WHILE: while

RETURN: return

PONTO_VIRGULA: ;

ABRE_COLCHETE: [

FECHA_COLCHETE:]

ABRE_PARENTESE: (

FECHA_PARENTESE:)

MENOR: <

MENOR_IGUAL: <=

MAIOR: >

MAIOR_IGUAL: >=


ATRIBUICAO: =

IGUAL: ==

DIFERENTE: !=

As quatro palavras reservadas também seguem a regra de ID. Por isso, o autômato usa 14 padrões; depois da leitura, uma tabela distingue essas palavras dos demais identificadores.

2.2. Construção do DFA:




Estado	Estados do NFA	Aceita	Transições
--------	----------------	--------	------------

A	{0,1,7,13,15,17,19,21,23,25,27,29,33,37,41}	não (inicial)	letter → B, digit → C, ; → D, [→ E,] → F, (→ G,) → H, < → I, > → J, = → K, ! → L
B	{2,3,4,6}	ID	letter → M
C	{8,9,10,12}	NUM	digit → N
D	{14}	;	
E	{16}	[	
F	{18}	]	
G	{20}	(	
H	{22}	)	
I	{24,30,31}	<	= → O
J	{26,34,35}	>	= → P
K	{28,38,39}	=	= → Q
L	{42,43}	não	= → R
M	{4,5,6}	ID	letter → M
N	{10,11,12}	NUM	digit → N
O	{32}	<=	
P	{36}	>=	
Q	{40}	==	
R	{44}	!=	

As transições que não aparecem na tabela vão para o estado de erro.

2.3. Minimização do DFA:



Começamos agrupando os estados pelo token aceito:

{B,M} {C,N} {D} {E} {F} {G} {H} {I} {J} {K} {O} {P} {Q} {R} {A,L,erro}

O último grupo precisa ser dividido. Com letter, A vai para B, mas L e erro vão para erro. Com =, L vai para R e erro continua em erro. Assim, A, L e erro ficam em grupos separados.

B e M podem ser unidos porque têm o mesmo resultado para qualquer entrada. O mesmo vale para C e N. Não há outras uniões. O DFA mínimo tem 16 estados, além do estado de erro. Na tabela, uma célula vazia indica transição para o estado de erro.

No código, A é INICIO, BM é EM_IDENTIFICADOR, CN é EM_NUMERO e I, J, K e L são os estados dos operadores. Os estados sem transição de saída devolvem o token assim que ele é lido.

2.5. Implementação:

O scanner manual está em `codigo/scanner_manual.c`. Ele lê os caracteres com `fgetc` e usa `ungetc` quando precisa devolver o caractere que já não faz parte do token. Isso permite reconhecer `<=` como um token e separar `x1` em `ID x` e `NUM 1`, conforme a regra da linguagem.

Depois de ler um ID, o scanner consulta a tabela de palavras reservadas. Espaços, tabulações e quebras de linha são descartados; as quebras de linha atualizam a numeração da saída. Um caractere fora do subconjunto, incluindo `!` sem `=`, produz ERRO. A leitura continua depois do erro.

Esse scanner não reconhece comentários, pois `/` e `*` não fazem parte do subconjunto. Ele guarda até 100 caracteres por lexema. Os dois scanners usam `codigo/scanner.h` e o mesmo programa de impressão, `codigo/principal.c`.

3. Scanner gerado com Flex:

As regras estão em `codigo/cminus.l`. O Flex reconhece os 27 tokens da linguagem completa: seis palavras reservadas, 19 símbolos, ID e NUM. As definições de letras, dígitos, identificadores e números seguem a seção A.1 do Louden.

O Flex escolhe o trecho mais longo da entrada. Quando duas regras reconhecem o mesmo trecho, vale a primeira. Por isso, as palavras reservadas aparecem antes da regra de identificador. `while` é reconhecido como palavra reservada e `whilex` como ID.

Os comentários começam com `/*`. Depois disso, usamos `input()` para ler até `*/` e contar as quebras de linha. A regra de espaços descarta os separadores, e um caractere não reconhecido produz ERRO.

No Flex 2.6.4 usado no trabalho, `input()` devolve 0 ao chegar ao fim do arquivo. Verificamos esse valor para que um comentário não fechado não prenda o scanner em um laço. Nesse caso, a saída mostra ERRO: `'/*'` na linha em que o arquivo termina. Também contamos as linhas dentro do comentário, porque os caracteres lidos por `input()` não passam pela regra normal de quebra de linha.

O Flex gera `codigo/lex.yy.c`. O Makefile compila esse arquivo com `principal.c` para produzir `scanner_flex`. O scanner manual é compilado separadamente com o mesmo `principal.c`.

4. Testes e saídas:

Executamos `make` para compilar os scanners, `make comparar` para comparar as saídas do subconjunto e `make completo` para rodar os exemplos da linguagem completa. Cada linha da saída mostra o token e sua linha no arquivo. A tabela resume os testes:

Arquivo	Scanner	O que testa	Resultado
valido1.cm	manual e Flex	declarações com int, void, vetores e números	sem erro
valido2.cm	manual e Flex	while, os seis operadores relacionais, = e return	sem erro
valido3.cm	manual e Flex	tokens sem espaço entre eles	sem erro
invalido1.cm	manual e Flex	! isolado	ERRO: '!' na linha 2
invalido2.cm	manual e Flex	caractere #	ERRO: '#' na linha 2
invalido3.cm	manual e Flex	@ no meio de um identificador	ERRO: '@' na linha 1, entre ID val e ID r
gcd.cm	Flex	exemplo do Louden: if, else, operadores aritméticos e comentários	sem erro
ordenacao.cm	Flex	exemplo do Louden: vetores, while, if e chamadas de função	sem erro
intervalo.cm	Flex	vetor, while, if e os operadores >, >=, <= e !=	sem erro
erros.cm	Flex	#, @, \$, ! isolado e comentário não fechado	5 erros, nas linhas 2, 3, 4, 5 e 7

Nos seis testes do subconjunto, as saídas dos dois scanners foram iguais.

A palavra “válido” aqui se refere apenas à análise léxica. Por exemplo, valido2.cm contém while fora de uma função; isso não afeta o teste do scanner.

Exemplo válido do subconjunto:

valido1.cm

Código:

```
int x;
int y;
void z;
int vetor[10];
int matriz[100];
```

Saída:

```
1: palavra reservada: int
1: ID, nome= x
1: ;
2: palavra reservada: int
```

```

2: ID, nome= y
2: ;
3: palavra reservada: void
3: ID, nome= z
3: ;
4: palavra reservada: int
4: ID, nome= vetor
4: [
4: NUM, valor= 10
4: ]
4: ;
5: palavra reservada: int
5: ID, nome= matriz
5: [
5: NUM, valor= 100
5: ]
5: ;

```

Exemplo com erro no subconjunto:

invalido1.cm

Código:

```

int x;
x = ! x;

```

Saída:

```

1: palavra reservada: int
1: ID, nome= x
1: ;
2: ID, nome= x
2: =
2: ERRO: '!'
2: ID, nome= x
2: ;

```

Abaixo estão um exemplo válido e um com erros da linguagem completa. As saídas dos outros arquivos estão na pasta `etapa1-analisador-lexico/saidas/`.

Exemplo válido da linguagem completa:

gcd.cm

Código:

```

/* A program to perform Euclid's
   Algorithm to compute gcd. */

```

```

int gcd (int u, int v)
{ if (v == 0) return u ;

```

```

    else return gcd(v,u-u/v*v);
    /* u-u/v*v == u mod v */
}

```

```

void main(void)
{ int x; int y;
  x = input(); y = input();
  output(gcd(x,y));
}

```

Saída:

```

4: palavra reservada: int
4: ID, nome= gcd
4: (
4: palavra reservada: int
4: ID, nome= u
4: ,
4: palavra reservada: int
4: ID, nome= v
4: )
5: {
5: palavra reservada: if
5: (
5: ID, nome= v
5: ==
5: NUM, valor= 0
5: )
5: palavra reservada: return
5: ID, nome= u
5: ;
6: palavra reservada: else
6: palavra reservada: return
6: ID, nome= gcd
6: (
6: ID, nome= v
6: ,
6: ID, nome= u
6: -
6: ID, nome= u
6: /
6: ID, nome= v
6: *
6: ID, nome= v
6: )
6: ;
8: }
10: palavra reservada: void
10: ID, nome= main

```

```

10: (
10: palavra reservada: void
10: )
11: {
11: palavra reservada: int
11: ID, nome= x
11: ;
11: palavra reservada: int
11: ID, nome= y
11: ;
12: ID, nome= x
12: =
12: ID, nome= input
12: (
12: )
12: ;
12: ID, nome= y
12: =
12: ID, nome= input
12: (
12: )
12: ;
13: ID, nome= output
13: (
13: ID, nome= gcd
13: (
13: ID, nome= x
13: ,
13: ID, nome= y
13: )
13: )
13: ;
14: }

```

Exemplo com erros na linguagem completa:

erros.cm

Código:

```

int x;
x = 10 # 3;
x = @;
x = 5 $ 2;
a ! b
/* comentario que nao fecha

```

Saída:

```

1: palavra reservada: int

```

1: ID, nome= x
1: ;
2: ID, nome= x
2: =
2: NUM, valor= 10
2: ERRO: '#'
2: NUM, valor= 3
2: ;
3: ID, nome= x
3: =
3: ERRO: '@'
3: ;
4: ID, nome= x
4: =
4: NUM, valor= 5
4: ERRO: '\$'
4: NUM, valor= 2
4: ;
5: ID, nome= a
5: ERRO: '!'
5: ID, nome= b
7: ERRO: '/'

5. Referencias:

LOUDEN, Kenneth C. Compiler Construction: Principles and Practice.

Lexical Analysis With Flex, for Flex 2.6.2. <https://westes.github.io/flex/manual/>